33

Nueva guía para expresiones regulares

Oliver Amadeo Vilca-Huayta
Universidad Nacional del Altiplano (UNA)

Ubaldo Yancachajlla Tito
Universidad Nacional de Juliaca (UNAJ)

Jorge Luis Apaza Cruz
Universidad Nacional del Altiplano (UNA)

Lelia Quispe Huamán
Universidad Nacional de Juliaca (UNAJ)

Ramiro Pedro Laura-Murillo
Universidad Nacional del Altiplano (UNA)

Fred Torres Cruz
Universidad Nacional del Altiplano (UNA)

René Leónidas Araujo Cotacallapa
Universidad Nacional del Altiplano (UNA)

doi 10.37885/230813995

RESUMEN

Las expresiones regulares (ER) sirven para representar lenguajes regulares y tienen diferentes aplicaciones. Se estudian en los cursos fundamentales de Ciencia de la Computación, pero su enseñanza/aprendizaje puede parecer difícil, debido a los teoremas, demostraciones, notaciones y su aparente complejidad. El **objetivo** de este trabajo fue desarrollar y evaluar una estrategia/herramienta de enseñanza con ejercicios seleccionados, para abordar las ER, los operadores, la precedencia y en general la adquisición de destrezas para resolver problemas. Primero se elaboró, un material práctico y novedoso conformado principalmente por una serie de ejercicios con un nivel incremental de dificultad. La **metodología** involucra la aplicación experimental de la estrategia y el material de enseñanza en diferentes grupos de estudiantes, es decir, en los cursos de "Teoría de Lenguajes y Autómatas" y "Teoría de la Computación" de los diferentes ciclos/años académicos, y la posterior medición de resultados mediante exámenes. **Los resultados** y la experiencia indican que la estrategia y las herramientas expuestas pueden ayudar eficientemente el proceso de enseñanza/aprendizaje. En **conclusión**, los resultados obtenidos mostraron que el uso del material proporcionó mejoras significativas, y fue bien recibido por los estudiantes. Finalmente, el material puede utilizarse como guía en la enseñanza.

Palabras-Clave: Expresiones Regulares, Fundamentos de Ciencia de la Computación, Lenguajes Regulares, Guía, Teoría de la Computación.

INTRODUCCIÓN

Uno de los temas fundamentales e importantes en Ciencia de la Computación, Ingeniería de Sistemas, y otras ramas; son las “expresiones regulares”. Conforman la primera o segunda unidad/sección del curso de Teoría de la Computación, Fundamentos de Ciencias de la Computación, Teoría de Lenguajes y Autómatas u otros. Adicionalmente, está estrechamente relacionado con otros temas (e.g. Autómatas Finitos). Por último, también está incluido en el curso de Compiladores y es tendencia en investigación debido a que es parte esencial de distintos tópicos (e.g. procesamiento de lenguaje natural, búsqueda de texto, etc.). Pero, el inconveniente es que su enseñanza y aprendizaje puede percibirse difícil, así lo demuestran algunos estudios sobre cursos de mayor dificultad en estudiantes universitarios (“IJCSNS - International Journal of Computer Science and Network Security”, [s.d.]).

Tiene extensa cantidad de aplicaciones, entre las pocas y recientes que se pueden mencionar están: “Detección automática de síntomas de depresión en Twitter mediante análisis multimodal” (SAFA; BAYAT; MOGHTADER, 2022), “Modelos de aprendizaje automático con datos de estabilidad extraídos de tres mil estructuras metalorgánicas” (NANDY *et al.*, 2022), diseño secuenciación y la identificación de códigos de barras de ADN aleatorios (JOHNSON; VENKATARAM; KRYAZHIMSKIY, 2023), “ZaligVinder: un marco de prueba genérico para solucionadores de cadenas” (KULCZYNSKI *et al.*, 2023), y otros (ALAVI; BORTOLINI; FORCADA, 2022; ALYAFEAI *et al.*, 2022; BIESNER *et al.*, 2022; HUO *et al.*, 2023; MUŠKARDIN *et al.*, 2022; PENG *et al.*, 2023; VOGEL; SCHULZE BALHORN; SCHWEIDTMANN, 2023). La lista irá aumentando.

Una expresión regular sirve como un descriptor de un lenguaje, también es una herramienta para describir patrones de texto, por ejemplo:

1. Se utiliza una notación similar a una expresión regular para describir patrones de búsqueda. Por ejemplo, en el procesamiento de documentos electrónicos, bioinformática, base de datos y en comandos de búsqueda como el GREP de UNIX.
2. En los generadores de analizadores léxico como el Lex y el Flex. El análisis léxico es una fase de un compilador que divide el código de entrada en unidades lógicas denominadas tokens de uno o más caracteres. Ejemplos de tokens son las palabras reservadas (ejemplo: if), identificadores y signos como +,>.
3. En búsqueda de texto flexible, se utiliza la expresión regular como un patrón de búsqueda, por ejemplo: a??bc[f-k] puede representar a todas las cadenas (palabras) de texto que inician con la “a” seguida de cualquier dos símbolos/caracteres, seguida de “bc”, y, finalmente un símbolo que puede ser desde la “f” hasta la “k”, es decir, uno del rango de símbolos comprendido entre la f y k. Hay un texto que abor-

da el tema: “Flexible Pattern Matching in Strings” (NAVARRO; RAFFINOT, 2014).

Expresiones regulares (HOPCROFT; MOTWANI; ULLMAN, 2006; LEWIS; PAPADIMITRIOU, 1997)

Una cadena (o algunas veces palabra) es una secuencia finita de símbolos escogidos de un alfabeto. Por ejemplo: aba es una cadena del alfabeto $\Sigma = \{a,b\}$.

La cadena vacía, es la cadena de cero ocurrencias de símbolos, es denotado por ϵ.

Longitud de una cadena. Es el número de símbolos (posiciones) de una cadena. Por ejemplo, aba tiene longitud 3. La notación para la longitud de una cadena w es $|w|$. Y $|\epsilon| = 0$ (la única cadena cuya longitud es cero).

La estrella de Kleene (o la clausura de Kleene). Dado un lenguaje L, se denota por L^*. Es la unión infinita $\cup_{i\geq 0} L^i$, donde $L^0 = \{\epsilon\}$, $L^1 = L$ y L^i, para $i > 1$ es $LLL\cdots L$, la concatenación de i copias de L.

Expresión regular. Se puede describir una expresión regular recursivamente como sigue:

Las constantes ϵ (cadena vacía) y $\emptyset$ (conjunto vacío) son expresiones regulares.

Si $a \in \Sigma$, es un símbolo, entonces a es una expresión regular.

Inducción: Si r y s son expresiones regulares entonces:

- r|s es una expresión regular, denota la unión de los lenguajes que representan dichas expresiones regulares.
- rs es una expresión regular, denota la concatenación. $r*$ es una expresión regular, denota la estrella de kleene.
- (r) es una expresión regular, denota el mismo lenguaje r.

Nota: Debido a que en algunos casos el operador “|” (unión) no es muy accesible desde el teclado de la computadora, en algunas aplicaciones como el JFLAP se utiliza el “+” y otros autores lo prefieren así.

Precedencia: Para evitar el uso exagerado de paréntesis se puede emplear la precedencia de operadores.

1. Operador unario “*”: Tiene la mayor precedencia y es asociativo por la izquierda, es decir, se aplica sólo a la secuencia más corta de símbolos a su izquierda que constituye una expresión regular.
2. La concatenación, o “punto”: tiene la segunda mayor precedencia y es asociativo por la izquierda. Este operador se representa con un punto, pero por fines prácticos se obvia, en su lugar se ubican los símbolos
3. La unión “|”: tiene la menor precedencia y es asociativo por la izquierda.

En ocasiones no se desea que una expresión regular sea agrupada según la precedencia de los operadores. En dicho caso, se puede emplear paréntesis para agrupar los operandos de la forma que se requiera.

Hay Software para manejar y convertir expresiones regulares (e.g. JFLAP) y herramientas de enseñanza de expresiones regulares, por ejemplo, el Regex Parser II y su predecesor (BROWN; HARDISTY, 2007; ROSENFELD; ADE-IBIJOLA; EWERT, 2017). Por otro lado, hay trabajos de investigación en expresiones regulares (ADE-IBIJOLA, 2018; BERZISH *et al.*, 2023; BLANCO ARBE; ORTEGA; MÁRTINEZ-CONDE, 2007). También se dispone de amplia bibliografía desde los libros clásicos (HOPCROFT; MOTWANI; ULLMAN, 2006) hasta libros recientes de teoría de la computación o compiladores.

El presente trabajo tiene por objetivo proponer una estrategia de enseñanza rápida y eficaz de la esencia de las expresiones regulares a través de ejercicios seleccionados que gradualmente llevan a comprender los operadores, precedencia y desarrollo de ejercicios con expresiones regulares.

Lo que resta de este trabajo está organizado de la siguiente manera: La sección de **Métodos**, expone los métodos y estrategias utilizadas, sigue la sección **Resultados**, muestra los resultados obtenidos, continúa la sección de **Discusión**, y finalmente, se expone las **Conclusiones** arribadas y **Referencias** utilizadas.

MÉTODOS

Rosenfeld (2017) y otros desarrollaron un juego educativo para mejorar y estimular el interés en expresiones regulares. En cambio, en este trabajo, se propone una estrategia de enseñanza a través de ejercicios clave que se muestran en la Tabla 1, la idea es ir al punto y desarrollar los ejercicios ilustrativos (esto a parte de la teoría), el tiempo que debería tomar es aproximadamente una hora, que incluye la explicación por parte del docente:

Tabla 1. Ejercicios para completar, equivalencia entre lenguaje y expresión regulares.

N.	Lenguaje regular	Expresión regular
1	$\{a,b\}$	$a\|b$
2	$\{\epsilon,b\}$	$\epsilon\|b$
3	$\{a,ab\}$	$a\|ab = a(\epsilon\|b)$
4	$\{abe,ace,_____\}$	$a(b\|c\|d)e$
5		$(a\|b)(a\|b)$
6		$(a\|b)(b\|c)(a\|b)$
7	$\{a,b,c,d\}$	$(a\|b)\|(c\|d) = a\|b\|c\|d$
8		$ab\|(ac)\|ad =$
9	$\{\epsilon,b,bb,bbb,bbbb,...\}$	b^*
10	$\{a,ab,abb,abbb,abbbb,...\}$	
11		$a(bb)^*$
12		ab^*c
13	$\{\epsilon,c,ab,cc,ccc,cccc,...\}$	$ab\|c^*$
14	$\{a,ab,abb,abbb,abbbb,...$ $ac,abc,abbc,abbbc,abbbbc,...\}$	$ab^*(\epsilon\|c) = ab^*\|ab^*c$
15	$\{\epsilon$	$a^*\|b^*$
16	$\{\epsilon$	a^*b^*
17	$\{ad$	$(a\|b)d(a\|b\|c)$
18		$(a\|b)^*$
19	$\{\epsilon,$	$((a\|b)c)^* =$
20	Todas las cadenas que se pueden formar con el alfabeto $\Sigma = \{a,b\}$, incluido la cadena vacía.	

El instructor puede iniciar explicando los tres primeros ejercicios resueltos, a continuación, para cada fila: Otorgar un tiempo prudencial para el que estudiante procure resolver el ejercicio (no resuelto que está en sin repuesta), luego, evaluar el logro de los estudiantes. Para terminar, puede resolverlo explicando la respuesta, así sucesivamente hasta culminar con todos los ejercicios.

Adicionalmente, con la finalidad de repasar en otra sesión, o como ejercicios para la casa, se puede utilizar los ejercicios de la Tabla 2: Construya una expresión regular para el alfabeto: $w \in \{0,1\}^*$

Tabla 2. Ejercicios de repaso, equivalencia entre lenguaje y expresión regulares. Construya una expresión regular para el alfabeto: $w \in \{0,1\}^*$.

Lenguaje regular	Resultado
w no contiene **0**, es decir, todos son unos	1^*
w tiene un **0**, es decir, tiene exactamente un cero. Ejemplo: 0, 10, 01, 011, 101, 110, ...	
	$11^*\ 0^*$
w contiene **00** como subcadena	
w tiene a lo más un **0**, es decir, tiene exactamente un cero o ningún cero. Ejemplo: 0, 1, 011, 1111, 111110, 11110111, ...	

Ahora queda preparado para resolver ejercicios de mayor dificultad.

Ejemplo: Dado el lenguaje formado con el alfabeto $\Sigma = \{a,b\}$ donde todas las cadenas no tienen la subcadena “aa” ni la subcadena “bb”. Es decir, el siguiente lenguaje:

L = {w ∈ {a,b}* : w no tiene la subcadenas “aa” ni “bb”}

Solución: Para obtener el resultado se ordena las cadenas (que se pueden generar) en tres partes, es decir, las tres filas de la Tabla 3, empleando la estrategia “Divide y reinaras”:

Tabla 3. El problema dividido en tres lenguajes regulares (divide y vencerás).

N.	Lenguaje regular
1	*ϵ*
2	*a,ab,aba,abab,ababa,ababab,...*
3	*b,ba,bab,baba,babab,bababa,...*

Para generar el primer conjunto de cadenas (primera y segunda fila) se tiene: (ab)*(alϵ). A este resultado se le debe incluir la expresión regular de la tercera fila, siendo el resultado: (ab)*(alϵ)l(ba)*(blϵ). No es la única solución, en la Tabla 4 se presenta otra solución:

Tabla 4. Soluciones del ejercicio.

N	Lenguaje regular	Solución 1	Solución 2
1	*ϵ*	*ϵ*	*ϵ*
2	*a,ab,aba,abab,ababa,ababab,...*	$(ab)^*(a\|\epsilon)$	$a(ba)^*(b\|\epsilon)$
3	*b,ba,bab,baba,babab,bababa,...*	$(ba)^*(b\|\epsilon)$	$b(ab)^*(a\|\epsilon)$
Solución general:		$(ab)^*(a\|\epsilon)$ | $(ba)^*(b\|\epsilon)$	$a(ba)^*(b\|\epsilon)$ | $b(ab)^*(a\|\epsilon)$

Si se simplifica o se combinan soluciones, por ejemplo: La solución 1 de la fila 2 con la solución 2 de la fila 3), se obtiene un resultado abreviado: (blϵ)(ab)*(alϵ), del mismo modo su recíproco: (alϵ)(ba)*(blϵ).

Evaluación de logros

El curso o tema se dictó en diferentes grupos desde hace más de 20 años, incluido el último grupo (semestre I del 2023) y se tiene la carga académica del próximo grupo semestre II del 2023. Se evaluó el aprendizaje a través de exámenes, cuyos resultados han sido gradualmente mejores. A continuación, en la tabla 5, se presentan las preguntas de exámenes:

Open Science Research XII - ISBN 978-65-5360-398-1 - Volume 12 - Ano 2023 - Editora Científica Digital - www.editoracientifica.com.br

Tabla 5. Preguntas de exámenes.

Grupo o semestre	Pregunta de examen (tema expresiones regulares)
2023-I Teoría de la Computación	Escriba una expresión regular para el siguiente lenguaje: [6 puntos] $L = \{a^m b^n : m + n \text{ es par}\}$
2022-I Teoría de Lenguajes y Autómatas	Escriba una expresión regular para el siguiente lenguaje: [5 puntos] $L = \{w \in \{0,1\}^* : w \text{ tiene una cantidad de 1's divisible por cinco}\}$
2012: Teoría de Lenguajes y Autómatas	Escriba una expresión regular para: $a^* b^* \cap b^* a^*$
2012: Teoría de Lenguajes y Autómatas	Escriba una expresión regular para la diferencia de los siguientes lenguajes: $a^* b^* - b^*$
2010: Teoría de Lenguajes y Autómatas	Escriba la expresión regular que genera el mismo lenguaje descrito por la siguiente gramática libre del contexto: [4p] E –> A c B A –> a A | ϵ B –> B b | B a | b Respuesta: $a*cb(a\|b)^*$

RESULTADOS

Se evaluó el aprendizaje en los diferentes grupos, el tema se impartió en la Escuela Profesional de Ingeniería de Sistemas de la Universidad Nacional del Altiplano, durante los últimos 20 años hasta el último semestre del 2023, incluso se dictará en el siguiente grupo (semestre II del 2023).

Los resultados de las evaluaciones son más que aceptables, con un porcentaje mayor a 85% de estudiantes que resolvieron la pregunta. Particularmente, en los dos últimos semestres, el porcentaje de estudiantes que resolvieron la pregunta es mayor al 90%. Se debe indicar que se reforzó con ejercicios, a veces con el JFLAP y con la impartición de la teoría.

DISCUSIÓN

Creemos que el resultado obtenido está también determinado por la pericia del docente, los materiales otorgados (por ejemplo, resumen con la teoría y la guía de práctica con las Tablas I y II), ejercicios asignados, conocimientos previos del estudiante (por ejemplo, un curso de introducción a la computación), y la dedicación de los estudiantes.

No obstante, tenemos la certeza que el material de enseñanza y su adecuada ilustración pueden jugar un rol importante en el logro de los objetivos.

Sugerimos primero se proporcione una sesión teórica (parte está en la Introducción). Luego, se otorgue: El resumen de clases, los ejercicios de la Tabla I, y otros para que el estudiante los resuelva. Puede desarrollarse mediante hojas impresas, una tableta con lápiz (ver un desarrollo en la Figura 1) u otro medio. En este punto, se puede tener consideración con los que no lograron resolver en el tiempo asignado para cada ejercicio. Finalmente, se explica la solución.

Figura 1. Ejercicios resueltos de la Tabla I.

	Lenguaje regular	Expresión regular
1.	$\{a, b\}$	$a\|b$ unión
2.	$\{\epsilon, b\}$ cadena vacia	$\epsilon\|b$
3.	$\{a, ab\}$ $a\|(ab) = a\|ab$	$a\|ab = a(\epsilon\|b) = a\epsilon\|ab$
4.	$\{abe, ace, ade\}$	$a(b\|c\|d)e$ ✓
5.	$\{aa, ab, ba, bb\}$	$(a\|b)(a\|b)$
6.	$\{a, b, c, d\}$	$(a\|b)\|(c\|d) = a\|b\|c\|d$
7.	$\{\epsilon, b, bb, bbb, bbbb, ...\}$	b^*
8.	$\{a, ab, abb, abbb, abbbb, ...\}$	ab^*
9.	$\{ac, abc, abbc, abbbc, ...\}$	ab^*c
10.	$\{\epsilon, c, ab, cc, ccc, cccc, ...\}$	$ab\|c^*$ Correcto
11.	$\{a, ab, abb, abbb, abbbb, \ldots$ $ac, abc, abbc, abbbc, abbbbc, \ldots\}$	$ab^*(\epsilon\|c) = ab^*\|ab^*c$

Fuente: Elaboración propia.

CONCLUSIONES

Por la naturaleza del tema, las expresiones regulares (en el curso de teoría de la computación, teoría de lenguajes y autómatas, o incluso en compiladores) suelen ser relativamente difícil, por lo que es importante contar con un método eficiente. Y, de esta forma, mantenerse en las tendencias de investigación, y en las aplicaciones que incluyen a las expresiones regulares.

Es importante que el instructor busque o adapte ejercicios, y elabore su material de enseñanza. Cada ciclo puede mejorar e incorporar más elementos o estrategias de enseñanza.

La estrategia y el material de enseñanza/aprendizaje es útil y puede tener resultados significativamente mejores en relación a no utilizar ningún material o a utilizar ejercicios improvisados u otras circunstancias que lo hagan desfavorable. Finalmente, los resultados obtenidos mostraron que el uso del material fue bien recibido por los estudiantes.

REFERENCIAS

1. ADE-IBIJOLA, A. Synthesis of regular expression problems and solutions. **https://doi.org/10.1080/1206212X.2018.1482398**, v. 42, n. 8, p. 748–764, 16 nov. 2018.
2. ALAVI, H.; BORTOLINI, R.; FORCADA, N. BIM-based decision support for building condition assessment. **Automation in Construction**, v. 135, p. 104117, 1 mar. 2022.
3. ALYAFEAI, Z. et al. Evaluating Various Tokenizers for Arabic Text Classification. **Neural Processing Letters**, v. 55, n. 3, p. 2911–2933, 1 jun. 2022.
4. BERZISH, M. et al. Towards more efficient methods for solving regular-expression heavy string constraints. **Theoretical Computer Science**, v. 943, p. 50–72, 17 jan. 2023.

5. BIESNER, D. et al. Anonymization of German financial documents using neural network--based language models with contextual word representations. **International Journal of Data Science and Analytics**, v. 13, n. 2, p. 151–161, 1 mar. 2022.

6. BLANCO ARBE, J. M.; ORTEGA, A. S.; MÁRTINEZ-CONDE, J. I. Formal languages through web forms and regular expressions. **ACM SIGCSE Bulletin**, v. 39, n. 4, p. 100–104, 1 dez. 2007.

7. BROWN, C. W.; HARDISTY, E. A. RegeXeX. **ACM SIGCSE Bulletin**, v. 39, n. 1, p. 445–449, 7 mar. 2007.

8. HOPCROFT, J.; MOTWANI, R.; ULLMAN, J. Introduction to Automata Theory, Languages, and Computation. p. 535, 2006.

9. HUO, Y. et al. SemParser: A Semantic Parser for Log Analytics. **2023 IEEE/ACM 45th International Conference on Software Engineering (ICSE)**, p. 881–893, maio 2023.

10. **IJCSNS - International Journal of Computer Science and Network Security**. Disponível em: <http://paper.ijcsns.org/07_book/html/201210/20121010.html>. Acesso em: 9 ago. 2023.

11. JOHNSON, M. S.; VENKATARAM, S.; KRYAZHIMSKIY, S. Best Practices in Designing, Sequencing, and Identifying Random DNA Barcodes. **Journal of Molecular Evolution**, v. 91, n. 3, p. 263–280, 1 jun. 2023.

12. KULCZYNSKI, M. et al. ZaligVinder: A generic test framework for string solvers. **Journal of Software: Evolution and Process**, v. 35, n. 4, p. e2400, 1 abr. 2023.

13. LEWIS, H. R.; PAPADIMITRIOU, C. H. Elements of the Theory of Computation: Finite automata. **Jama**, v. 80, n. 17, p. 1265, 1997.

14. MUŠKARDIN, E. et al. AALpy: an active automata learning library. **Innovations in Systems and Software Engineering**, v. 18, n. 3, p. 417–426, 1 set. 2022.

15. NANDY, A. et al. MOFSimplify, machine learning models with extracted stability data of three thousand metal–organic frameworks. **Scientific Data 2022 9:1**, v. 9, n. 1, p. 1–11, 11 mar. 2022.

16. NAVARRO, G.; RAFFINOT, M. Flexible pattern matching in strings: Practical on-line search algorithms fortexts and biological sequences. **Flexible Pattern Matching in Strings: Practical on-line Search Algorithms Fortexts and Biological Sequences**, p. 1–221, 1 jan. 2014.

17. PENG, Z. et al. CLIP: accurate prediction of disordered linear interacting peptides from protein sequences using co-evolutionary information. **Briefings in Bioinformatics**, v. 24, n. 1, 19 jan. 2023.

18. ROSENFELD, A.; ADE-IBIJOLA, A.; EWERT, S. Regex parser II: Teaching regular expression fundamentals via educational gaming. **Communications in Computer and Information Science**, v. 730, p. 99–112, 2017.

19. SAFA, R.; BAYAT, P.; MOGHTADER, L. Automatic detection of depression symptoms in twitter using multimodal analysis. **Journal of Supercomputing**, v. 78, n. 4, p. 4709–4744, 1 mar. 2022.

20. VOGEL, G.; SCHULZE BALHORN, L.; SCHWEIDTMANN, A. M. Learning from flowsheets: A generative transformer model for autocompletion of flowsheets. **Computers & Chemical Engineering**, v. 171, p. 108162, 1 mar. 2023.